

國立中興大學資訊工程學系

碩士學位論文

利用基於聯邦學習的條件生成對抗網路
實現人群流量預測

Using Federated Learning-Based Conditional
Generative Adversarial Networks to Implement the
Prediction of Crowd Flow

指導教授：陳奕中 Yi-Chung Chen

研究生：李軍磊 Chun-Lei Lee

中華民國一百一十三年八月

國立中興大學 資訊工程學系
碩士學位論文

題目：利用基於聯邦學習的條件生成對抗網路實現人群流
量預測

姓名：李軍磊 學號：7111056417

經 口 試 通 過 特 此 證 明

論文指導教授 陳奕中

論文考試委員 林傑森

葉明峰

陳奕中

中華民國 113 年 6 月 28 日

致謝

在整個碩士生涯與論文的撰寫過程中，我得到了許多人的幫助與支持，我在此衷心感謝他們。

首先，我要感謝我的指導教授陳奕中教授。他在我研究的每一個階段都給予了無私的指導和建議，無論是在研究方向的确立還是論文撰寫的細節上，他都提供了寶貴的意見。他的學術造詣與嚴謹態度不僅幫助我完成了這篇論文，也讓我研究過程中受益匪淺。

此外，我還要感謝我的家人。他們在我攻讀碩士期間給予了我全力的支持與理解，無論是生活上的照顧還是精神上的鼓勵，都讓我能夠專心致志地投入到學業中。

同時，我也要感謝實驗室的同學與朋友們，博士班的阮揚洲與施長宏學長在我研究的過程中給予了很多非常實用的建議，同時在參加研討會的過程中也給予了我很多的幫助。同屆的于善齊與王亮鈞同學在寫論文的過程中互相討論進行研究，還有學弟蔡季憲、吳曷儒、李展偉在參與競賽及口試準備都幫了非常多的忙。

最後，我要感謝所有在此研究過程中幫助過我的人。你們的支持與鼓勵讓我得以順利完成這篇論文，感謝你們！

摘要

隨著時空大數據建模技術的逐漸成熟，越來越多模型開始可以進行高精準度的人流預測。因此許多 AI 產品開發商開始試著將這個技術落地化，其能透過這個技術帶給商業界與政府最大的幫助。然而眾所皆知的是，人流預測技術在落地時仍有兩大問題還未被克服，包含(1)長期預測結果經常不準確，以及(2)如何合法取得多來源的人流歷史資料，讓該技術在落地的時程上不斷被延後。也因此，本論文嘗試透過導入兩大概念來克服這兩大問題，包含(1)採用條件式生成對抗網路而非傳統深度學習模型來進行人流預測，並因此達成高精準度的人流長期預測。(2)在建模過程中導入聯邦學習的概念，讓模型建置商可以在不把所有資料聚集在一起的情況下，完成模型的建置。最終本論文的實驗模擬則驗證了我們所提出方法的有效性。

關鍵字：條件式生成對抗網路、聯邦學習、都市人流預測、時空間資料

Abstract

Advances in spatiotemporal big data modeling technology have greatly improved the accuracy of crowd flow predictions for business and government. However, long-term prediction results remain unreliable, and researchers face legal constraints when accessing historical crowd flow data. This paper proposes a Conditional Generative Adversarial Network (CGAN) as an alternative to conventional deep learning models for crowd flow prediction. The proposed model employs federated learning, which facilitates the collaborative training of a model on a central server by sharing gradients or parameters, instead of raw data. This approach provides access to valuable information from multiple sources (e.g., cell phones) without compromising data privacy. Simulations demonstrated the efficacy of the proposed method in making crowd flow predictions of high precision over extended durations.

Keywords : Conditional Generative Adversarial Network, Federated Learning, City Crowd Flow Prediction, Spatiotemporal Data

目次

摘要	i
Abstract.....	ii
目次	iii
圖目次	v
表目次	vi
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究目的	3
1.3 研究範圍及限制	4
1.4 論文架構	5
第二章 文獻回顧	6
2.1 人流預測	6
2.2 生成對抗網路	7
2.3 聯邦學習	9
第三章 資料集	11
3.1 目標資料集	11
3.2 輔助資料集	12
第四章 研究方法	13
4.1 資料預處理	13
4.2 時空間特徵處理	15
4.3 FL-CF-CGAN.....	16
4.4 ONLINE 階段	20
4.5 實驗效能評估指標	21
第五章 實驗模擬	23
5.1 實驗環境及參數介紹	23
5.2 基於聯邦學習的條件式生成對抗網路模型實驗結果	23
5.3 多網格預測實驗	23
5.4 生成對抗網路對聯邦學習影響實驗	24
5.5 用戶數量影響實驗	25
5.6 溝通次數實驗	26

5.7 質化討論.....	26
第六章 結論與未來研究建議.....	28
參考文獻.....	29

圖目次

圖 1、電信商市占率	3
圖 2、人流資料範圍	11
圖 3、FL-CGAN 系統流程圖	13
圖 4、(a) 人流資料補值前，(b) 人流資料補值後	14
圖 5、(a) 人流資料標準化前，(b) 人流資料標準化後	15
圖 6、滑動視窗示意圖	16
圖 7、生成器架構圖	17
圖 8、判別器架構圖	18

表目次

表 1、人流資料範例	11
表 2、天氣資料特徵欄位	12
表 3、FL-CF-CGAN 實驗結果	24
表 4、生成對抗網路對聯邦學習影響實驗	24
表 5、多網格預測影響實驗	25
表 6、用戶增加預測影響實驗	25
表 7、溝通次數影響實驗	26
表 8、質化實驗各用戶之間的於弦相似度	27
表 9、質化實驗結果	27

第一章 緒論

1.1 研究背景與動機

近年來，大數據相關技術爆發，機器學習的技術也逐漸被應用在各個領域之中。隨著技術的發展與應用的需求，資料型態也在不斷的演化及複雜化，從最早的離散資料開始演化成帶有先後關係的線性資料，再到包含空間資訊的空間資料，過程中誕生了各種帶有不同資訊的資料型態。其中，時空間資料同時擁有時間上及空間上的資訊，結合了時序資料與空間資料的優點，包含的資訊更加全面，模型在學習的過程中能夠學習到更多有用的特徵。在時空間資訊的眾多應用中，都市人流的分析及預測是目前非常重要的議題之一[44]，預測人流可以幫助企業和政府機構更有效地優化資源配置，從而提升整體運營效率和服務質量。比如，在公共交通系統中，基於人流預測數據，運營單位可以根據不同時段和地點的預測客流量，精細化調整公交班次和路線安排，這不僅能夠減少乘客等待時間，提升乘客滿意度，還能有效降低運營成本。此外，在高峰時段增加運力，或在低峰時段減少空車運行，均能達到更合理的資源分配，最大化交通運營效益。在零售業和商業地產管理中，人流預測數據也扮演著至關重要的角色。商場和零售店鋪可以根據預測的人流變化，合理安排員工班次、庫存管理以及促銷活動。例如，在預計人流量較大的節假日或促銷活動期間，提前增派人手並準備足夠的庫存，能夠有效應對突如其來的購物潮，避免因人手不足或庫存短缺而導致的銷售損失和顧客不滿。同時，根據人流預測進行的促銷活動，能夠精確地吸引目標顧客群體，提高銷售轉化率。在人流異常檢測方面，時空間資料提供的精確預測能夠及時發現和應對各種突發情況。例如，在大型活動或突發事件（如自然災害或公共安全事件）期間，快速準確地掌握人流變化，有助於相關部門迅速作出反應，部署應急資源，確保公共安全。此外，通過持續監測和分析人流數據，可以預測和提前應對潛在的問題，如某些地區可能出現的人潮擁擠或安全隱患，從而提前採取措施，避免問題惡化。

明顯從上述案例看來，若我們能有效做好人流預測，則不管是對政府還是企業來說都會是一大福音，因此值得我們耗費精力進行研究。

過往有很多人流預測相關的文獻，這些文獻中的方法大致可以被分為三類，包含統計方法、機器學習方法及深度方法。在統計方法的研究中，Zhang 等人[1]使用 Seasonal Autoregressive Integrated Moving Average 方法進行城市高速公路車流量預測，Hoang 等人[2]則是將人流拆解為季節流量、趨勢流量及殘餘流量，並使用 Intrinsic Gaussian Markov Random Fields 模型進行預測，統計方法在應用上有數學理論上的支持且計算快速，但是無法應對特徵複雜的情況。在機器學習方法的部分，Su 等人[3]利用 Incremental Support Vector Regression 進行車流的短期預測。Cheng 等人[4]提出使用 Adaptive Spatiotemporal K-Nearest Neighbor 解析道路交通的空間異質性，實現車流預測。相較於統計方法在的應用，機器學習方法在人流預測的方法論更加多元，且能過處理更複雜的資料型態，但無法處理資料在時序上的關係。在深度學習方法的部分，Zhene 等人[5]將卷積神經網路與遞迴神經網路結合，應用於都市交通工具乘客人流預測，Liu 等人[6]提出了 Attentive Traffic Flow Machine 一種全新的注意力機制，並宣稱它們的方法能夠協助模型專注於重要因子上的建模，從而得到遠比過往其他方法優秀的結果。明顯從上述的說明看來，深度學習模型在人流預測上確實能提供比過往方法更準確的結果，並讓人流預測的研究得以進入落地階段。

目前人流預測在落地時遇到最大的問題有三者，分別是(1)人流預測目前在短期預測時(泛指預測時間<3小時)才會準確，但在長期預測時則十分不準確[43]。(2)目前人流預測最常見是用電信信號資料集達成，但眾所皆知，不管是哪一國，其電信商都不可能由單一家獨佔。像台灣來說，人流資訊的獲取通常來自於電信商從各基地台紀錄的行動網路訊號，由此推估各區域當時的人流。根據 NCC 公開的資訊，台灣電信商市佔率由高到低排列分別是中華電信 32.7%、台灣大哥大 27.9%、遠傳 26.5%與其他電信商 12.9%。同時，民眾對於電信商的選用也會根據收入、年齡、性別、居住地區等因素而有所差異，根據 NCC 的統計，16~25 歲的民眾已台灣大哥大占比最高，而 66 歲以

上的民眾則是以中華電信占比最高。而這樣的情況也代表若政府要進行人流預測，就必須先跟多家電信商進行協調，取得各家電信商的資料後才能進行，十分曠日廢時。

(3) 人流預測為網格時序預測的一種應用，過往方法想要在預測時有精準的預測效果，大多針對每個網格獨立建立模型，也就是說預測範圍的大小會極大程度的影響模型訓練及維護的成本。以本研究的目標地區為例，整個台北市就包含 900 多個網格，若是以過往的方法進行建模，需要花費大量的時間及金錢成本。明顯從上述討論中，我們可以看到人流預測在落地前仍有兩大困難點需要克服，而這也是本論文演算法被開發出來的目的。




圖 1、電信商市占率

1.2 研究目的

針對上述提到的三個人流預測落地問題，長期預測、多來源的資料集與範圍預測成本高昂。本論文將分別提出生成對抗網路、聯邦學習、篩選核心網格三大概念來克服，以下分別說明我們方法的概念。

首先是生成對抗網路的介紹。眾所皆知，這個網路的特色是能在看過部分真實資料後，產生擬真的虛擬資料，並因此被大量運用在假人臉生成[7][8]、假音樂生成

[9][10]等。而對於本論文來說，我們則是希望透過該網路如此的特性，讓網路看過特定狀況歷史人流資料後，外來在遇到類似狀況時，能產生該狀況下的擬真人流，而如此的作法，其時之前也有鄭學者提出[43]，並驗證其有效性。但因為其做法過於暴力，不同時間段的預測需要建立不同模型才能完成建模過程，而這將會耗費難以想像的運算資源。因此本論文也將基於它的想法，建立更適用於人流長期預測的生成對抗網路方法。接著，為了處理多資料來源的問題，我們將在目標模型上導入聯邦學習的概念來進行訓練。所謂的聯邦學習是 Google 於 2016 年[11]提出的一種分散式學習架構，其他的分散式學習方法通常希望透過平行運算的方式來增加模型訓練的效率，聯邦學習最大的不同是它是為了保障在多用戶的訓練過程中不會違反歐盟 GDPR 規範，訓練的過程中，各用戶不需要交換各自的資料，而是透過共享模型訓練過程產生的梯度來實現分散式學習。共享梯度也意味著訓練過程的溝通成本會隨著模型本身的大小成正比，前面有提到條件式生成對抗網路是由兩個子模型所組成的，為了降低溝通成本，本實驗在訓練過程中只會共享生成器的梯度，判別器則是各用戶內部獨立訓練。而藉由如此的訓練方式，我們期望模型能在不集中所有資料集的情況下完成模型的訓練，並因此避免多來源資料集在獲得上的問題。最後針對模型範圍預測成本的問題，本研究提出使用篩選核心網格的方式來解決。由於人流是有方向性的，鄰近的網格之間通常會有密切的關係，作為交通要道的網格通常會有更複雜的人流波動，我們希望能夠將這些網格作為核心網格輸入進模型進行附近區域的範圍預測。

1.3 研究範圍及限制

本論文所使用得人流資料集由於基地台遷移或是其他不可控因素，可能會產生缺失值的情況，為了保障實驗模擬的正確性，本論文在模擬的過程中僅會使用台北市區域的資料。此外，由於 2019 年底爆發 COVID-19，為了避免潛在的要素影響模型，本論文中使用的資料時間範圍為 2018 年 1 月 1 日至 2019 年 12 月 31 日。同時，礙於資料集的限制，本論文中會透過切割現有的資料級來模擬多資料集的情況，專注於模擬

方法論的可行性。

1.4 論文架構

本論文的論文架構主要可以分為六個章節，分別是(1)緒論，這個章節會介紹研究的動機、目的、範圍、限制及論文的整體架構、(2)文獻探討，這個章節會藉少與本論文使用資料集、方法論相關的文獻、(3)資料集，這個章節會介紹本論文使用的目標資料集與輔助資料集、(4)研究方法，這個章節會藉少本論文提出的基於聯邦學習的條件式生成對抗網路的架構與流程、(5)實驗模擬，這個章節會透過量化討論與值化討論來驗證方法論的可行性、(6)結論與未來研究建議，這個章節會針對整篇論文進行結論，並提出未來可能的研究方向。

第二章 文獻回顧

本章節將會分別介紹與本論文相關的研究文獻，分為人流預測、生成對抗網路、聯邦學習三個子章節。

2.1 人流預測

人流預測通常被視為是一種時序預測的問題，相較於其他時序預測問題，人流資料最大的特點它是一種時空間資料(Spatiotemporal data)，資料之前不僅存在時序上的關係，同時也有空間上的關係。這使得在過去的文獻中，各式各樣的方法被應用在人流預測中，從方法論上看的話可以分為統計方法、機器學習方法與深度學習方法三種，若是從特徵提取的角度看，則可以分為時間、空間及時空間，這些分類彼此可存在重疊，過往有很多文獻透過結合方法論來實現更好的效能。在部分文獻中，有些學者以統計模型為基礎再進一步改良，如 Zhang 等人[12]於 2011 年時將 Seasonal Autoregressive Integrated Moving Average 與 Support Vector Machine 相結合，透過線性模型與非線性模型的組合，克服短期預測常受到季節性特徵影響的問題，實現精確的短期車流預測，又或是 Chen 等人[13]於 2019 年將 Autoregressive Integrated Moving Average 統計模型與 Generalized Autoregressive Conditional Heteroscedasticity 模型結合，提出了 Hybrid Autoregressive Integrated Moving Average Nonlinear and Asymmetric Generalized Autoregressive Conditional Heteroscedasticity 模型，用於短期特殊事件的地鐵人流預測，並應用於南京地鐵的資料集。

也有學者的研究以機器學習方法為主，如 Li 等人[14]於 2013 年提出了 Gauss Support Vector Machine，增強了模型在處理資料序列常態分佈隨機誤差的能力，並以渾沌雲粒子群優化演算法優化 Gauss Support Vector Machine 模型的超參數克服超參數設定困難的問題，應用於都市交通流量預測；Hong 等人[15], [16]於 2011 年先後發表了兩篇論文，將對於時序預測已經有不錯效果的支持向量回歸模型分別與連續蟻群優化演算法與混和遺傳-模擬退化演算法結合提出了透過渾沌雲粒子群優化演算法優化的高斯支持向量回歸模型與透過混和遺傳-模擬退化演算法優化的高斯支持向量回歸模型，透過

優化最佳超參數的方式，提升支持向量回歸模型在城市交通流量預測的準確度。由於支持向量回歸模型在時序預測上有很不錯的效果，很多文獻都是基於它去改良的，但也有一派人使用 K-Nearest Neighbor 來實現人流的預測，K-Nearest Neighbor 的優勢在於不需要訓練，而是透過取鄰近點的方式來實現預測，像是 Yu 等人[17]於 2012 年提出基於 K-Nearest Neighbor 的短期交通流量預測，以四種不同狀態的向量作為輸入，透過貴陽市的 GPS 資料進行驗證。Xia 等人[18]於 2016 年提出了 Spatial-Temporal Weighted K-Nearest Neighbor，強化了 K-Nearest Neighbor 在時空間資料上的預測準確性及效率，同時透過在 Hadoop 分散式運算平台上實作，實現及時交通流量預測。

隨著深度學習的崛起，近年來也開始有學者將深度學習技術應用於人流預測上面，Hu 等人[19]於 2020 年提出了 Weighted Resample Bidirectional Recurrent Neural Network，透過加權並重新採樣的方式解決資料不平衡的問題，應用於 Mass Rapid Transit 系統的壅擠程度預測。Zhang 等於[20]於 2018 年時提出了 Spatio-Temporal Residual Network，它能夠有效的提取輸入資料的時間、空間、氣候資訊特徵，並透過北京及紐約的人流資料進行驗證。Narmadha 等人[21]於 2021 年提出了 Convolutional Neural Network-Long Short Term Memory，同時提取卷積神經網路在空間特徵提取與長短期記憶模型在時間特徵提取上的長處，實現精準的短期交通流量預測。

2.2 生成對抗網路

生成對抗網路是 Goodfellow 等人於 2014[22]提出的一種非監督式深度學習神經網路模型並將其應用在圖片生成上。生成對抗網路模型由兩個子模型所組成，生成器(Generator)與判別器(Discriminator)，在訓練的過程中，兩個子模型會互相對抗學習，最後則會獲得兩個訓練好的模型，分別式能夠生成與輸入資料相似假資料的生成器與能夠判別資料真假的判別器。生成對抗網路憑藉著其獨特的架構與生成以假亂真資料的特性，被應用在各個場景之中。在初始論文的基礎上，有非常多的研究在圖片生成進一步演化，Jin 等人[23]於 2017 年時透過整合複數個生成對抗網路，將其應用於動漫角色生成。Ledig 等人[24]於 2017 年提出 Super-Resolution Generative Adversarial Network，

引入了感知損失的技術，生成出高解析度的逼真圖片。Li 等人[25]於 2020 年在生成對抗網路的基礎上，又引入了彈性權重鞏固技術(EWC)，避免模型在小樣本訓練中過度擬合，實現極少資料下的圖像生成技術。除去圖片生成相關的應用，過往也有很多研究將生成對抗網路用於別的資料類型，Pascual 等人[26]於 2017 年提出了 Speech Enhancement Generative Adversarial Network，利用生成器將受損的語音信號增強並去噪，在經由判別器分析語音品質的後，實現語音增強的應用。Ramponi 等人[27]於 2018 年提出了 Time-Conditional Generative Adversarial Network，將條件式生成對抗網路應用於增強時間序列資料，對於採樣時間短、噪點多且不平衡的資料有不錯的效果。Nie 等人[28]於 2019 年提出了 Relational Generative Adversarial Network，由用於長距離依賴建模的關係記憶生成器、用於離散數據的 Gumbel-Softmax relaxation 及多重嵌入判別器三個部分組成，應用於文本的生成。Geiger 等人[29]於 2020 年提出了 Time series Anomaly Detection Generative Adversarial Network，一種用於時先序列資料異常偵測的生成對抗網路，將長短期記憶模型(LSTM)與生成對抗網路模型結合，捕捉時間序列分布的時間相關性。

原始的生成對抗網路各領域皆有不錯的效果，但由於輸入的限制，存在不穩定的要素，後續也有很多學者針對這項缺點進行改良，其中最著名的兩個模型便是條件式生成對抗網路(Conditional GAN)與循環生成對抗網路(Cycle GAN)，前者於 2014 年由 Mirza 等人[30]提出，相較於基礎的生成對抗網路，條件式生成對抗網路的輸入加入了有助於模型判斷的資訊，這使生成對抗網路能夠適應更複雜的情況，生成出更符合需求的結果。與生成對抗網路不同，條件式生成對抗網路在訓練的過程中除了亂數(Noise)以外，還需要輸入條件標籤(Condition)。有了條件標籤，生成器就能更具目標性的生成假資料。Isola 等人[31]於 2016 年將條件式生成對抗網路應用於圖像生成，將素描作為條件輸入，透過生成器將其轉換為照片，是一種 Pix2Pix 的技術。循環生成對抗網路最早由 Zhu 等人[32]於 2017 年提出，條件式生成對抗網路的訓練資料通常需要條件輸入與生成資料相匹配才能進行訓練，循環生成對抗網路則是為了解決這個問題而被提出的，資料進入循環生成對抗網路後會在 2 個 Domain 之間互相轉化，實現圖像的轉換。

Chen 等人[33]於 2018 年提出了 Cartoon Generative Adversarial Network，在循環神經網路的基礎上引入語意內容損失與邊緣促進對抗損失，在保留原有圖片基本架構的情況下，將其轉換為帶有卡通風格的圖像。

2.3 聯邦學習

聯邦學習是 Google 於 2016 年[11]提出的一種分散式學習策略，目的是要在不會違反歐盟 GDPR 規範的前提優化用戶的智慧輸入法(Gboard)，被視為是一種不得不的分散式學習。聯邦學習的基礎概念在於參與訓練的各用戶資料不需要被整合，而是獨立訓練，再透過整合訓練過程產生的梯度共同訓練模型。近期已經有非常多相關的文獻及應用了，McMahan 等人[11]於 2016 提出了 算法，相較於原始論文中同步隨機梯度下降的方式，大幅減少了模型訓練過程的溝通次數。Bonawitz 等人[34]於 2016 年提出了一種全新的安全梯度聚合協定，保障再模型更新聚合時，中央伺服器也無法獲取用戶的隱私數據且不會顯著的影響模型的效能。Liu 等人[35]於 2020 年將聯邦學習與 5G 的技術結合，提出了一種基於區塊鏈的聯邦學習安全架構，利用智能合約防止惡意的用戶參與聯邦學習的過程。Reddi 等人[36]於 2020 年提出了自適應聯邦優化演算法，透過基於 Adagrad、Adam 與 Yogi 等算法的自適應最佳化器進行訓練，解決了過往方法難以整的問題。

除了以上基於聯邦學習基礎架構的演化及更新研究，聯邦學習也被廣泛利用在各個需要保障隱私安全的應用場景中，像是在醫療領域，Houda 等人[37]於 2023 年提出了 HealthFed，將聯邦學習與區塊鏈技術相結合，在多個用戶之間實現安全的去中心化分散式學習。Sheller 等人[38]於 2020 年將聯邦學習應用於 10 個醫療機構之間的深度學習模型訓練，整合了過往基於安全隱私問題而無法實現的大規模資料集。

在金融領域，Imteaj 等人[39]於 2022 年將聯邦學習應用於 Give me Some Credit 資料集，並透過實驗證實，在資源有限的環境下，能夠發揮比其他方法更好的效果。Byrid 等人[40]於 2020 年將聯邦學習與多方安全計算技術結合，提出了一種全新的保護隱私的聯邦學習協定，並透過真實的信用卡詐騙資料集進行驗證。

聯邦學習在物聯網的應用上也有不少相關的研究，Savazzi 等人[41]於 2020 年將聯邦學習原有的中心化架構進行改良，在物聯網應用上實現去中心化的架構，解決了網路規模增加的擴展問題。Wu 等人[42]於 2020 年提出了個人化聯邦學習方法，將聯邦學習架構與雲端邊緣(Edge Computing)架構結合，減輕了不同面向異質性造成的影響，同時透過邊緣運算的優勢，滿足物聯網應用中對於快速處理能力及低延遲的需求。

第三章 資料集

本論文中使用到的資料集有三個，分別是人流資料集、天氣資料集與日曆資料集，人流資料集為目標資料集，作為條件式生成對抗網路還原的目標，天氣資料集與日曆資料集則為輔助資料集，作為條件式生成對抗網路的條件輸入進模型，輔助目標資料集的預測，以下分別進行介紹。

3.1 目標資料集

本論文使用來自某電信商的行動人流資料集，資料涵蓋的時間範圍為 2018 年 1 月 1 日至 2019 年 12 月 31 日，空間範圍則如圖 2 所示，本論文只使用台北市區域的資料，每筆資料會提供時間、經緯度與人流的資訊，如表 1，經緯度為 500*500 公尺的網格中心，但礙於保密協定的關係，我們無法在提供更多的細節。




圖 2、人流資料範圍

表 1、人流資料範例

Timestamp	Longitude	Latitude	Population
2018-01-01 00:00:00	121.53	25.115	274
2018-01-01 01:00:00	121.53	25.115	254
...
2019-12-31 23:00:00	121.53	25.115	268

3.2 輔助資料集

天氣資料使用來自交通部中央氣象署氣候資料服務系統(CWB Observation Data Inquire System)的資料，此網站以小時為單位提供台灣各氣象站點收集到的資訊，提供的資料欄位共有 16 欄，各欄位名稱及說明如表 2。日曆資料則是根據日期對應的相關資訊，包含了假日、平日、周末與節日等資訊。

表 2、天氣資料特徵欄位

Feature	Unit	Description
StnPres	hPa	測站氣壓
SeaPres	hPa	海平面氣壓
Temperature	°C	氣溫
Td dew point	°C	露點溫度
RH	%	相對溼度
WS	m/s	風速
WD	Degree	風向
WSGust	m/s	最大瞬間風
WDGust	Degree	最大瞬間風向
Precp	mm	降雨量
PrecpHour	Hour	降雨時數
SunShine	Hour	日照時數
GlobRad	MJ/m ²	全天空日射量
Visb	Km	能見度
UVI	Number	紫外線指數
Cloud	0~10	總雲量

第四章 研究方法

本章節將會介紹本論文提出的基於聯邦學習的條件式生成對抗網路系統流程，應用於長期的都市人流預測，系統流程圖如圖 3，分為 Offline 階段與 Online 階段。Offline 階段主要可以分為三個部分，(1)資料預處理，這個部分又包含缺失值處理與資料正規化、(2)時空間特徵處理，這個部分包含篩選劇烈變動網格及時間序列切割、(3)模型訓練，這個部分包含條件式生成對抗網路訓練與聯邦學習策略。Online 階段則是將用戶的資料經過預處理後，輸入各用戶訓練好的 FL_CGAN 模型，最後再將輸出的結果進行整合得到都市人流的預測值。

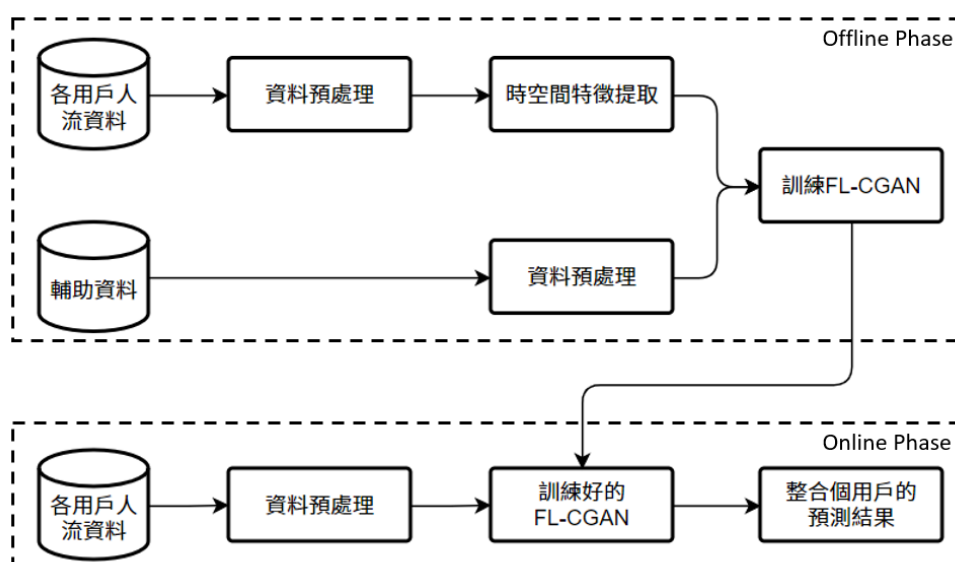


圖 3、FL-CGAN 系統流程圖

4.1 資料預處理

根據過往的經驗，原始資料在資料型態、值域與格式等等方面，可能無法很好的契合模型，適當處理對於模型最後的成果有很大的幫助。此節將會介紹應用於本論文的兩個資料預處理方法，分別是(1)缺失值處理與(2)資料正規化。

4.1.1 缺失值處理

資料在收集或傳輸的過程中可能會遇到一些無法控制要因素，進而導致資料缺失的問題，這些缺失值會導致模型學習到錯誤的資訊，最終嚴重影響模型的效果。因此，在輸入進模型訓練之前，需要先將這些缺失的資料補齊。常見的處理方式是使用內插法，公式如(1)。

$$X(t) = \frac{X(t-1) + X(t+1)}{2} \quad (1)$$

$X(t)$ 為在 t 時間的資料，透過前一個時間段的資料 $X(t-1)$ 與後一個時間段的資料 $X(t+1)$ 相加取平均來填補中間缺失的資料，保障資料在時間上的連續性，補值前後的效果如圖 4。




圖 4、(a) 人流資料補值前，(b) 人流資料補值後

4.1.2 資料正規化

不同區域的人流數值可能會有巨大的差異，在平日市中心可能會有數千甚至上萬的人流，相反郊區可能只有幾百人不到，因此需要將這些數值正規化至 0~1 之間，以方便模型學習。本論文中使用的正規化方法為 Min-Max 正規化，公式如(2)。

$$X = \frac{X' - \min(X')}{\max(X') - \min(X')} \quad (2)$$

X' 為標準化前的序列資料，透過這個公式就能夠將整條序列資料等比縮放至 0~1 之間，最終的效果如圖 5。此外，各網格之間可能會存在趨勢相似，但是數值差異巨大的情況。因此，本論文會針對每個網格獨立進行標準化，讓模型各網格的趨勢，而不是數值。




圖 5、(a)人流資料標準化前，(b) 人流資料標準化後

4.2 時空間特徵處理

雖然經過預處理的資料能夠直接訓練模型，但模型需要花費更多時間，甚至更大的架構才能有效的處理輸入的資訊。此節將會介紹本論文做的兩項特徵處理，分別是(1)空間特徵處理與(2)時間特徵處理。

4.2.1 空間特徵處理

都市人流的範圍很大，其中包含了的人流網格大致可以被分為兩類，分別是有劇烈變動的網格及變化穩定的網格，前者隨著時間的變化，數值也會跟著劇烈的變化，後者則是較為平穩甚至長時間人流為 0 的網格，若是將所有的網格直接輸入模型會造成模型過於臃腫。此外，有劇烈變動的網格往往也意味著帶有更多的資訊，模型在訓練後也能更好的進行預測。本論文透過標準差(standard deviation)作為指標將各行政區的網格進行排序，並將標準差最大的網格作為特徵輸入進模型進行預測。

4.2.2 時間特徵處理

前一節以標準差為指標篩選了劇烈變動的特徵，在空間方面對資料進行特徵處理，本節將以時間的角度從原始資料提取特徵。時間序列資料的相關性通常會隨著時間而遞減，本論文中透過滑動視窗(Sliding Window)的方式擷取時間特徵，概念圖如圖 6。




圖 6、滑動視窗示意圖

4.3 FL-CF-CGAN

本節會介紹基於聯邦學習的條件式生成對抗網路模型的整體架構及流程，架構的部分會分成兩個部分，分別介紹本研究中所使用的條件式生成對抗網路的兩個子模型，生成器及判別器。再來流程的部分會介紹本論文如何將條件式生成對抗網路與聯邦學習結合。




圖 7、生成器架構圖

4.3.1.1 生成器架構

生成器的架構由輸入層(Input Layer)、隱藏層(Hidden Layer)與輸出層(Output Layer)組合而層。其中隱藏層又可以分為嵌入層(Embedding Layer)、相乘層(Multiply Layer)及全連接層(Fully Connect Layer)所組成。圖 7 為生成器的詳細架構。隱藏層中的各層，根據計算的方式可以被分為兩種，分別是全連接層與相乘層，全連接層的公式如(3)。

$$y(x) = f(W \cdot x + b) \quad (3)$$

其中 $y(x)$ 為輸出特徵(Output Feature)， W 為該層的權重矩陣(Weights Matrix)， x 為輸入特徵(Input Feature)， b 為偏移量(Bias Term)， f 為激活函數(Activation Function)，輸入的特徵會與權重矩陣相乘，再加上偏移量，最後經過激活函數的轉換得到輸出特徵，神經網路就是透過不斷的訓練改善權重矩陣與偏移量的值來學習。本論文中全連接層所使用的激活函數為 Tangent Sigmoid(Tanh)，Tangent Sigmoid 的輸出會落在-1 到 1 之間，相較於其他的激活函數，Tangent Sigmoid 的值域更廣且具有對稱性，模型在更新的過程中會更加的穩定，公式如(4)。

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (4)$$

相乘層的則是透過逐元素(Element-wise)的方式將兩個張量(Tensor)相乘，透過這種方式整合兩個張量，這種作法相較於直接將兩個張量連結(Concatenate)能夠更結合的更緊密，在後續隱藏層的操作中，也不會遺失任意一個張量的特徵，公式如(5)。

$$X_i = A_i \times B_i \quad (5)$$

輸入的資料為經過預處理及時空間特徵提去後的資料，包含了人流資訊、天氣資訊與日曆資訊，這些資料會經由輸入層傳入模型並進入隱藏層，隱藏層的開頭為嵌入層，資料進入嵌入層後，輸入的特徵會被嵌入至與雜訊相同的維度，接下來就會傳入相乘層與雜訊相結合，這也是條件式生成對抗網路的特點，相較於普通的生成對抗

網路直接將雜訊做為輸入，條件式生成對抗網路以相乘的方式避免輸入條件或是雜訊其中一方在模型訓練中遺失的可能性。後續這些與雜訊相結合特徵會經過連續的全連接層降維並傳至輸出層，由於人流預測是一種回歸問題，所以在本研究中，輸出層沒有設定激活函數，而是直接線性輸出。




圖 8、判別器架構圖

4.3.1.2 判別器架構

判別器在整個生成對抗網路的架構中扮演非常重要的角色，透過判別輸入資料是否為生成器生成的假資料的方式，反饋給生成器，讓生成器學習如何生成與真實資料相似的假資料。相較於普通的生成對抗網路只需要將真假資料直接輸入讓判別器判斷真假，條件式生成對抗網路的判別器還需要判斷輸入的條件與資料是否匹配，所以在輸入進模型之前，就需要將條件與這些真假資料合併。本論文中使用的判別器詳細架構如圖 8，大致可以被分為三個部分，輸入層、隱藏層與輸出層，合併後的資料會經由輸入層傳入模型進入隱藏層，隱藏層內部包含多層的全連接層，透過先升維再降維的方式萃取出有用的特徵，期間隱藏層的激活函數皆為 Tangent Sigmoid，最後進入輸出層，對比生成器使用線性的方式輸出，判別器需要將結果做二元分類，所以本研究在輸出層的激活函數選擇使用 Sigmoid 函數，Sigmoid 的公式如(6)。

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (6)$$

Sigmoid 能夠將輸入映射至 0~1 之間，輸出的值可以被視為分類問題的機率，因此廣泛的被應用在二元分類模型的輸出層。

4.3.2 訓練流程

本節將介紹會介紹基於聯邦學習的條件式生成對抗網路的訓練流程，大致可以分為 3 個步驟，分別是(1)參數初始化、(2)梯度計算、(3)模型整合，並不斷重複步驟(2)及步驟(3)直到模型訓練完成。

4.3.2.1 參數初始化

如 4.4.1 章節提到的，相同初始參數的模型會往相同的方向收斂，所以在第一次訓練前，中央伺服器就需要統一初始化模型的參數，然而，聯邦學習方法的溝通成本與模型架構大小成相關，所以在本研究中，用戶之間只會共享條件式生成對抗網路的其中一個子模型，也就是負責生成資料的生成器。相反的，判別器則會由各用戶獨自持有，因此，在初始化階段，各用戶需要自行初始化判別器的模型參數。各用戶也會在這個階段使用 4.1 章節與 4.2 章節提到的資料預處理及時空間特徵提取方法對原始資料做處理，方便後續的訓練。上述步驟都執行完後，中央伺服器就會將模型參數共享給參與訓練的各用戶，並進行下一個步驟。

4.3.2.2 梯度計算

各用戶在從中央伺服器接收到初始化(或整合)後的模型後，就會開始使用手上的資料對模型進行訓練。在 4.3 章節介紹生成對抗網路的時候有提到，生成對抗網路相較於一般監督式神經網路模型最大的差異便是生成對抗網路的子模型式透過相互訓練來學習，而不是透過標籤梯度下降。生成器會將生成的假資料傳給判別器判斷真假，在透過判別器回傳的布林值進行梯度下降，由於生成器希望判別器判斷不出假資料，所以需要將判別器回傳的布林值預同樣長度且值為 1 的陣列計算損失值(Loss)，判別器則

是根據真資料與假資料判斷結果進行梯度下降。這段過程中，由於判斷真假屬於二元分類的分之二，本研究中使用二元交叉熵(Binary Crossentropy)作為損失函數(Loss Function)，公式如(7)。

$$BCE = \frac{1}{N} \sum_{i=1}^N [y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)] \quad (7)$$

雖然生成器與判別器是透過相同的方式進行學習，但是生成以假亂真的資料與判別資料真假的難度有明顯的差異，在訓練的過程中，判別器在強度上可能會越差越多，最後判別器在每輪訓練中都能判別出生成器生成的假資料，這會使生成器無法有效的學習。所以本研究在訓練的過程中，會採用交替訓練的策略，讓生成器在學習上能夠跟上判別器強度。

各用戶透過上述的方式訓練完模型後，便會將訓練過程中產生的梯度回傳給中央伺服器進行整合，雖然在 4.4.3 章節有提到梯度安全傳輸的概念，但是本研究旨在討論方法論的可行性及有效性，此處與傳輸過程安全相關的議題便不詳細討論。

4.3.2.3 模型整合

中央伺服器在接收到各用戶回傳梯度後，就需要將這些梯度進行整合才能夠進行下一輪的訓練。本研究使用聯邦學習初始論文提出的 FedAvg 對收到的梯度進行整合，公式如(8)。

$$w_{t+1} = \sum_{k=1}^K \frac{n_k}{N} \cdot w_{t+1}^k \quad (8)$$

在 4.4.1 章節有提到，相同初始值的參數會往相同的方向梯度下降，透過 FedAvg 算法，各用戶分享的梯度在訓練的過程中會互相拉扯，同時達到防止模型過擬合(Overfitting)的效果。

4.4 Online 階段

相較於一般的模型訓練完後上線就可以值皆使用，人流資料不管在模型上線前後，各電信商的資料都是獨立的。換句話說，即使模型成功訓練上線，也需要個電信商將其手上及時的人流資料各別輸入進模型，之後再將模型預測的值進行整合，才能得到真實的人流。Online 階段的流程如圖 O 所示，首先各用戶需要將手上的資料經過 4.1 章節與 4.2 章節提到的方法進行預處理及時空間特徵提取，再將這些資料傳入已經訓練完成的條件式生成對抗網路模型的生成器進行預測，由於訓練過程的資料都是經過標準化的，所以此處模型輸出的結果就需要經過反標準化才能夠反映實際的樹值，反標準化的公式如(9)。

$$x = x' \times (\max(x) - \min(x)) + \min(x) \quad (9)$$

A 為訓練資料中，該網格的最大值，B 為最小值，這些資訊只會存在電信商的本地端，所以各電信商需要各自值型反標準化的運算再將預測的值傳給中央伺服器，中央伺服器在接收到各電信商傳送的預測人流後，就可以透過相加的方式將這些人流預測值整合在一起，並進行後續的應用。

4.5 實驗效能評估指標

本實驗透過 MAE(Mean Absolute Error)、MAPE(Mean Absolute Percentage Error)、MSE(Mean Square Error)與 RMSE(Root Mean Square Error)作為衡量模型準確率的指標，MAE、MSE 與 RMSE 作為回歸問題與數值預測問題常見的指標，能夠直觀反映的成效，公式如(10)(11)(12)。

$$MAE = \frac{1}{N} |Y_i - \hat{Y}_i| \quad (10)$$

$$MSE = \frac{1}{N} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \quad (11)$$

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(Y_i - \hat{Y}_i)^2}{N}} \quad (12)$$

上述三種指標雖然都有著數值越小越好的特性，但最終呈現的數值會受到預測值的數量級影響。在人流資料中，各電信商資料在相同位置會有不同數量級的人流，透過前面介紹的三種指標無法客觀的衡量模型的好壞，本研究在此基礎上加入 MAPE (Mean Absolute Percentage Error)作為衡量各電信商模型訓練好壞的標準。MAPE 的數值以百分比為表示方法，不會受到數量級的影響，同時，MAPE 呈現的是預測值與實際值的相對比例，對於各用戶模型成效的評估相較於前面三種指標更加合理，公式如(13)。

$$MAPE = \frac{1}{N} \sum_{i=1}^n \frac{|Y_i - \hat{Y}_i|}{Y_i} * 100\% \quad (13)$$

第五章 實驗模擬

5.1 實驗環境及參數介紹

本研究的實驗皆在 CPU 為 i7-13700，GPU 為 RTX 4090，記憶體 64G，作業系統為 Ubuntu 的裝置上執行。在實驗的過程中，批量大小(Batch Size)為 32、學習率(Learning Rate)為 0.0005、以每輪 2 代(Epoch)的方式執行 45 輪聯邦學習(Federated Learning Round)。由於台灣三大電信商在台灣的電信商市佔率占比 87%，本研究中會以三個用戶為基礎進行。

5.2 基於聯邦學習的條件式生成對抗網路模型實驗結果

從表 3 中可以看到，加入聯邦學習策略後，由於訓練的過程中，各用戶產生的梯度會互相拉扯，模型在預測上有更好的表現。同時不管有無聯邦學習，整合後的結果普遍比整合前的各用戶獨立預測好，推測可能是各模型之間的差值有互補的效果，即使單一模型預測失準，其他的模型也能夠減少它帶來的影響。同時，對比於總體來說，基於聯邦學習的條件式生成對抗網路模型在人流預測上有著不錯的效果，後續將會對模型有跟深入的實驗並討論。

5.3 多網格預測實驗

輸入與輸出一對一的模型雖然很常見，但是在人流預測的領域並不適用，一對一代表每個網格需要獨立建立模型，這會使空間成本與時間成本過高，常見的方法便是進行一對多或是多對多的預測。本節將進行多網格預測的實驗，討論增加預測網格數量對 FL-CF-CGAN 造成的影響。結果如表 4 所示，各指標的結果皆與預測網格數量成正相關，不過直到預測網格增加至 3 為止，FL-CF-CGAN 仍保有不錯的效果，後續實驗預測效果變差應該是模型大小本身的限制，隨著問題的複雜程度稍微調整模型的大小，就可以改善效能。

表 3、FL-CF-CGAN 實驗結果

	MSE	RMSE	MAE	MAPE
FL-CF-GAN Client 1	148320.95	385.1246	274.8703	8.3232%
FL-CF-GAN Client 2	479743.78	692.6354	573.5096	12.0996%
FL-CF-GAN Client 3	195237.89	441.8573	334.8883	10.4627%
FL-CF-GAN Integrate	1450857.4	1204.5154	986.8384	9.2521%
CF-CGAN Client 1	779151.125	882.6954	703.0322	19.5045%
CF-CGAN Client 2	1751617.375	1323.4868	1067.5551	19.7901%
CF-CGAN Client 3	1002240.1875	1001.1193	811.7442	30.0967%
CF-CGAN Integrate	5427015	2329.5955	1615.5125	12.48%
CF_CGAN Union	339384.1875	582.5669	436.5811	9.9631%

5.4 生成對抗網路對聯邦學習影響實驗

聯邦學習作為一種通用的學習策略，能夠被套用在各種常見的神經網路架構，但是在條件式生成對抗網路模型的架構中包含著兩個功能與不相同的網路互相訓練，要如何將這兩項技術結合在一起並發揮各自的優勢會是一大挑戰。最簡易的方式就是將整個生成對抗網路模型一起回傳給中央伺服器進行梯度的整合，但是這種作法會大幅增加訓練過程中的溝通成本，本研究的做法則是只對生成對抗網路模型中的生成器進行聯邦學習，判別器則是保留在用戶的本地端進行訓練。由表 4 可以看到，將整個條件式生成對抗網路一起進行聯邦學習反而會造成結果不佳，在訓練的過程中，判別器會學習各電信商人流的趨勢，並透過分享梯度傳遞到其他電信商，這會導致生成器在學習的過程中學習到錯誤的趨勢，進而導致成效不佳。透過將判別器獨立出來再各電信商本地端訓練則可以很好的解決這個問題，同時也降低聯邦學習過程中的溝通成本。

表 4、生成對抗網路對聯邦學習影響實驗

	MSE	RMSE	MAE	MAPE
Separate Client 1	148320.95	385.1246	274.8703	8.3232%
Separate Client 2	479743.78	692.6354	573.5096	12.0996%
Separate Client 3	195237.89	441.8573	334.8883	10.4627%
Separate Integrate	1450857.4	1204.5154	986.8384	9.2521%
Whole Client 1	504511.3	710.2896	560.6846	18.4983%
Whole Client 2	765128.8	874.7164	653.9085	12.2694%
Whole Client 3	1408843	1186.947	974.1357	32.6975%
Whole Integrate	6306305	2511.236	1918.562	17.5746%

5.5 用戶數量影響實驗

雖然台灣目前電信服務市佔率主要由三大電信商包攬，但還是有許多中小型的電信商，在每間電信商用戶不完全重複的情況下，越多的電信商參與訓練，出來的結果就越能反映真實的人流，本節將討論將會以次為標準，討論參與模型訓練的用戶數量對於 FL-CF-GAN 的影響。表 5 為實驗結果，在訓練的過程中，雖然需要花費更多的算力，但是各用戶之間平行計算梯度，在時間成本上只有整合梯度的步驟會增加，同時更多用戶也代表最後人流預測整合時有更多數據，這也使模型最後的效果更好。

表 5、多網格預測影響實驗

	MSE	RMSE	MAE	MAPE
1 Grid	1450857	441.8573	986.8384	9.2521%
2 Grids	2467961	374.0692	1215.489	10.3737%
3 Grids	2321966	538.7097	1170.036	10.6603%
4 Grids	3074904	897.0164	1355.394	12.0257%
5 Grids	4011995	785.1464	1550.663	13.6771%
6 Grids	3903967	955.8378	1484.678	13.0772%
7 Grids	3333231	579.5342	1406.405	13.4140%
8 Grids	5291165	1287.495	1687.531	15.6564%
9 Grids	10521369	6101.043	2158.514	16.7105%
10 Grids	6900796	1800.032	2187.456	19.6410%

表 6、用戶增加預測影響實驗

	MSE	RMSE	MAE	MAPE
3 Clients	1450857	1204.5154	986.8384	9.2521%
4 Clients	3784256	1945.3166	1597.1167	9.8632%
5 Clients	2482169	1575.4903	1323.7699	8.5502%
6 Clients	3482033	1866.0206	1476.9019	7.8249%

表 7、溝通次數影響實驗

EPOCH Per Round	FL Round	MSE	RMSE	MAE	MAPE
2	45	1450857	1204.5154	986.8384	9.2521%
3	30	1558331	1248.3313	1031.7633	9.4206%
5	18	1626493	1275.3405	1110.224	10.345%
6	15	1029220	1014.5051	766.6837	6.5811%
9	10	1495241	1222.8007	939.3845	8.5789%
10	9	2666588	1632.9691	1226.502	9.7355%
15	6	1509243	1228.5126	991.696	8.2016%
18	5	1205783	1098.0818	849.4738	7.7097%
30	3	1459947	1208.2831	980.1919	9.0715%
45	2	851391	922.7088	686.8467	5.8337%

5.6 溝通次數實驗

聯邦學習的訓練過程中，計算梯度過程中都是各用戶平行運算，總 EPOCH 相同的情況下，溝通次數會直觀的影響訓練時間，同時每輪溝通的時候，都需要傳遞模型的梯度，整個過程需要花費大量的時間及成本，於是溝通次數便成了能夠反映時間成本最直接的指標。表 6 為溝通實驗的結果，從表中可以看到，相同 EPOCH 的前提下，各項指標有好有壞，但都是生成對抗網路預測產生的誤差，推測可能是個用戶預測網格的相似度夠高，在最後整合模型時，可以達到相同的效果。

5.7 質化討論

本節將進行質化討論實驗，目的在於使用差異化較大的網格進行實驗，以驗證 FL-CF-GAN 在極端情況下依然可以有良好的效果。表 7 為三個用戶之間的餘弦相似度，表 8 為實驗結果，從表中可以看到套用 FL-CF-GAN 後效果有明顯的改善，人流量較少的用戶更容易受到突發事件影響，進而導致它與其他用戶的差異性提升，透過 FL-CF-GAN 方法，共同訓練後能夠減輕突發事件對整體預測帶來的影響，進而提升整體的效能。

表 8、質化實驗各用戶之間的於弦相似度

	Client 1	Client 2	Client 3
Client 1		-0.427	0.7533
Client 2	-0.427		-0.6446
Client 3	0.7533	-0.6446	

表 9、質化實驗結果

	MAE	MSE	RMSE	MAPE
Client 1	281.7252	141892	376.6861	5.6992%
Client 2	41.3167	2452	49.5248	6.5503%
Client 3	512.1659	488410	698.8638	8.2918%
Integrate	657.15656	742418	861.63727	5.7451%

第六章 結論與未來研究建議

本研究針對人流資料來源的特殊性，考慮資料隱私安全上的問題，無法直接對資料進行整合，提出了 FL-CF-GAN 來解決這個問題。根據過往的研究，生成對抗網路本身雖然已經在時間序列長期預測上有不錯的成果，但是缺乏多資料集共同訓練的能力，同時為了保障各用戶的資料在訓練的過程中不會有隱私外泄的可能性，本研究在生成對抗網路的基礎上加入了聯邦學習的訓練架構，共享梯度的方式來代替資料在各用戶之間的共享，從而解決安全性上的問題。多電信商共同預測不只更符合台灣不前主流電信服務使用的情況，整合多用戶的方式，FL-CF-GAN 對於歷史資料中的離群值有更高的容忍度。在第五章的實驗環節，本研究使用真實的人流資料搭配天氣資料與日曆資料作為輔助，對 FL-CF-GAN 的效能進行驗證，各電信商的預測結果經過整合的後，準確度普遍上升。

在本研究中使用基礎的模型架構對方法論的可行性進行討論，未來可以針對以下幾個方向進行延伸(1)人流資料作為一種時空間資料，在未來可以考慮加入遞迴神經網路的架構，增加模型對於資料前後關係特徵提取的能力。(2)在模型的空間特徵提取能力上突破，強化模型的多網格預測能力。(3)對於生成對抗網路與聯邦學習的節合配置進行討論，探討生成器與判別器在共享或私有情況下的影響。

參考文獻

- [1] B. M. Williams, P. K. Durvasula, and D. E. Brown, "Urban Freeway Traffic Flow Prediction: Application of Seasonal Autoregressive Integrated Moving Average and Exponential Smoothing Models," *Transp. Res. Rec.*, vol. 1644, no. 1, pp. 132–141, Jan. 1998.
- [2] M. X. Hoang, Y. Zheng, and A. K. Singh, "FCCF: forecasting citywide crowd flows based on big data," in *Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems*, in SIGSPACIAL '16. New York, NY, USA: Association for Computing Machinery, pp. 1–10, Oct. 2016.
- [3] H. Su, L. Zhang, and S. Yu, "Short-term Traffic Flow Prediction Based on Incremental Support Vector Regression," in *Third International Conference on Natural Computation (ICNC 2007)*, pp. 640–645, Aug. 2007.
- [4] S. Cheng, F. Lu, P. Peng, and S. Wu, "Short-term traffic forecasting: An adaptive ST-KNN model that considers spatial heterogeneity," *Comput. Environ. Urban Syst.*, vol. 71, pp. 186–198, Sep. 2018.
- [5] Z. Zhene et al., "Deep Convolutional Mesh RNN for Urban Traffic Passenger Flows Prediction," in *2018 IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Cloud & Big Data Computing, Internet of People and Smart City Innovation (SmartWorld/SCALCOM/UIC/ATC/CBDCoM/IOP/SCI)*, pp. 1305–1310, Oct. 2018.
- [6] L. Liu et al., "Dynamic Spatial-Temporal Representation Learning for Traffic Flow Prediction," *IEEE Trans. Intell. Transp. Syst.*, vol. 22, no. 11, pp. 7169–7183, Jan. 2021.
- [7] N. Ud Din, K. Javed, S. Bae, and J. Yi, "A Novel GAN-Based Network for Unmasking of Masked Face," *IEEE Access*, vol. 8, pp. 44276–44287, 2020.

- [8] Z. Fang, Z. Liu, T. Liu, C.-C. Hung, J. Xiao, and G. Feng, "Facial expression GAN for voice-driven face generation," *Vis. Comput.*, vol. 38, no. 3, pp. 1151–1164, Mar. 2022.
- [9] S. Walter, G. Mougeot, Y. Sun, L. Jiang, K.-M. Chao, and H. Cai, "MidiPGAN: A Progressive GAN Approach to MIDI Generation," in *2021 IEEE 24th International Conference on Computer Supported Cooperative Work in Design (CSCWD)*, pp. 1166–1171, May 2021.
- [10] F. Guan, C. Yu, and S. Yang, "A GAN Model With Self-attention Mechanism To Generate Multi-instruments Symbolic Music," in *2019 International Joint Conference on Neural Networks (IJCNN)*, pp. 1–6, Jul. 2019.
- [11] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-Efficient Learning of Deep Networks from Decentralized Data," in *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, PMLR, pp. 1273–1282, Apr. 2017.
- [12] N. Zhang, Y. Zhang, and H. Lu, "Seasonal Autoregressive Integrated Moving Average and Support Vector Machine Models: Prediction of Short-Term Traffic Flow on Freeways," *Transp. Res. Rec. J. Transp. Res. Board*, vol. 2215, pp. 85–92, Dec. 2011.
- [13] E. Chen, Z. Ye, C. Wang, and M. Xu, "Subway Passenger Flow Prediction for Special Events Using Smart Card Data," *IEEE Trans. Intell. Transp. Syst.*, vol. 21, no. 3, pp. 1109–1120, Mar. 2020.
- [14] M.-W. Li, W.-C. Hong, and H.-G. Kang, "Urban traffic flow forecasting using Gauss–SVR with cat mapping, cloud model and PSO hybrid algorithm," *Neurocomputing*, vol. 99, pp. 230–240, Jan. 2013.

- [15] W.-C. Hong, Y. Dong, F. Zheng, and C.-Y. Lai, "Forecasting urban traffic flow by SVR with continuous ACO," *Appl. Math. Model.*, vol. 35, no. 3, pp. 1282–1291, Mar. 2011.
- [16] W.-C. Hong, Y. Dong, F. Zheng, and S. Y. Wei, "Hybrid evolutionary algorithms in a SVR traffic flow forecasting model," *Appl. Math. Comput.*, vol. 217, no. 15, pp. 6733–6747, Apr. 2011.
- [17] Bin Y. U., Shan-hua W. U., Ming-hua W., and Zhi-hong Z., "K-nearest neighbor model of short-term traffic flow forecast," *交通运输工程学报*, vol. 12, no. 2, pp. 105–111, Apr. 2012.
- [18] D. Xia, B. Wang, H. Li, Y. Li, and Z. Zhang, "A distributed spatial–temporal weighted model on MapReduce for short-term traffic flow forecasting," *Neurocomputing*, vol. 179, pp. 246–263, Feb. 2016.
- [19] R. Hu, Y.-C. Chiu, and C.-W. Hsieh, "Crowding prediction on mass rapid transit systems using a weighted bidirectional recurrent neural network," *IET Intell. Transp. Syst.*, vol. 14, no. 3, pp. 196–203, 2020.
- [20] J. Zhang, Y. Zheng, D. Qi, R. Li, X. Yi, and T. Li, "Predicting citywide crowd flows using deep spatio-temporal residual networks," *Artif. Intell.*, vol. 259, pp. 147–166, Jun. 2018.
- [21] S. Narmadha and V. Vijayakumar, "Spatio-Temporal vehicle traffic flow prediction using multivariate CNN and LSTM model," *Mater. Today Proc.*, vol. 81, pp. 826–833, Jan. 2023.
- [22] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative Adversarial Nets," in *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2014.
- [23] Y. Jin, J. Zhang, M. Li, Y. Tian, H. Zhu, and Z. Fang, "Towards the Automatic Anime Characters Creation with Generative Adversarial Networks." *arXiv*, Aug. 18, 2017.

- [24] C. Ledig, L. Theis, F. Huszar, J. Caballero, A. Cunningham, A. Acosta, A. Aitken, A. Tejani, J. Totz, Z. Wang, and W. Shi, "Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network," presented at the *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 4681–4690, 2017.
- [25] Y. Li, R. Zhang, J. Lu, and E. Shechtman, "Few-shot Image Generation with Elastic Weight Consolidation." *arXiv*, Dec. 04, 2020.
- [26] S. Pascual, A. Bonafonte, and J. Serrà, "SEGAN: Speech Enhancement Generative Adversarial Network." *arXiv*, Jun. 09, 2017.
- [27] G. Ramponi, P. Protopapas, M. Brambilla, and R. Janssen, "T-CGAN: Conditional Generative Adversarial Network for Data Augmentation in Noisy Time Series with Irregular Sampling." *arXiv*, Feb. 01, 2019.
- [28] W. Nie, N. Narodytska, and A. Patel, "A GAN-based Attack on Text-based CAPTCHAs." *arXiv*, Dec. 18, 2018.
- [29] A. Geiger, D. Liu, S. Alnegheimish, A. Cuesta-Infante, and K. Veeramachaneni, "TadGAN: Time Series Anomaly Detection Using Generative Adversarial Networks," in *2020 IEEE International Conference on Big Data (Big Data)*, Atlanta, GA, USA: IEEE, pp. 33–43, Dec. 2020.
- [30] M. Mirza and S. Osindero, "Conditional Generative Adversarial Nets." *arXiv*, Nov. 06, 2014.
- [31] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, "Image-To-Image Translation With Conditional Adversarial Networks," presented at the *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1125–1134, 2017.
- [32] J.-Y. Zhu, T. Park, P. Isola, and A. A. Efros, "Unpaired Image-To-Image Translation Using Cycle-Consistent Adversarial Networks," presented at the *Proceedings of the IEEE International Conference on Computer Vision*, pp. 2223–2232, 2017.

- [33] Y. Chen, Y.-K. Lai, and Y.-J. Liu, “CartoonGAN: Generative Adversarial Networks for Photo Cartoonization,” presented at *the Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 9465–9474, 2018.
- [34] K. Bonawitz et al., “Practical Secure Aggregation for Federated Learning on User-Held Data.” *arXiv*, Nov. 14, 2016.
- [35] Y. Liu, Y. Kang, C. Xing, T. Chen, and Q. Yang, “A Secure Federated Transfer Learning Framework,” *IEEE Intell. Syst.*, vol. 35, no. 4, pp. 70–82, Jul. 2020.
- [36] S. Reddi et al., “Adaptive Federated Optimization.” *arXiv*, Sep. 08, 2021.
- [37] Z. A. E. Houda, A. S. Hafid, L. Khoukhi, and B. Brik, “When Collaborative Federated Learning Meets Blockchain to Preserve Privacy in Healthcare,” *IEEE Trans. Netw. Sci. Eng.*, vol. 10, no. 5, pp. 2455–2465, Sep. 2023.
- [38] M. J. Sheller et al., “Federated learning in medicine: facilitating multi-institutional collaborations without sharing patient data,” *Sci. Rep.*, vol. 10, no. 1, p. 12598, Jul. 2020.
- [39] A. Imteaj and M. H. Amini, “Leveraging asynchronous federated learning to predict customers financial distress,” *Intell. Syst. Appl.*, vol. 14, p. 200064, May 2022.
- [40] D. Byrd and A. Polychroniadou, “Differentially private secure multi-party computation for federated learning in financial applications,” in *Proceedings of the First ACM International Conference on AI in Finance*, in ICAIF ’20. New York, NY, USA: Association for Computing Machinery, pp. 1–9, Oct. 2021.
- [41] S. Savazzi, M. Nicoli, and V. Rampa, “Federated Learning With Cooperating Devices: A Consensus Approach for Massive IoT Networks,” *IEEE Internet Things J.*, vol. 7, no. 5, pp. 4641–4654, May 2020.
- [42] Q. Wu, K. He, and X. Chen, “Personalized Federated Learning for Intelligent IoT Applications: A Cloud-Edge Based Framework,” *IEEE Open J. Comput. Soc.*, vol. 1, pp. 35–44, 2020.

- [43] 鄭佳昇（民111年）。基於3D-RCL與條件是生成對抗網路產生未來時刻人群分布之可能性探討(未出版之碩士論文)。國立雲林科技大學，雲林縣。
- [44] 詹大千（民107年4月6日）。從手機網路訊號資料，探勘人口動態奧妙(張語辰 & 廖英凱, Eds.)【新聞群組、線上論壇或討論群組】。取自 <https://research.sinica.edu.tw/human-dynamics-chan-ta-chien/>